المندوبية السامية للتخطيط
HAUT-COMMISSARIAT AU PLAN

INSEA
Institut National de Statistique et d'Économie Appliquée

INSEA

Rapport du projet encadré

Sujet : Evaluation des méthodes de classification pour Détection de fraude par carte de crédit

Réalisé par : **Riyad LAGZOULI**
Mohamed Nabil OUAJA

Filière : **Data Science**

INSEA – Rabat

Table des matières

Liste des figures **3**

Introduction Générale **4**

1 Fondements Théoriques **5**
1.1 La fraude bancaire : définition, typologie et enjeux 5
1.2 Apprentissage automatique pour la classification 5
1.3 Algorithmes de classification 6
1.3.1 Régression Logistique 6
1.3.2 Arbres de décision et Forêts Aléatoires 6
1.3.3 Gradient Boosting : XGBoost et LightGBM 6
1.4 Le problème du déséquilibre de classes 6
1.4.1 Sur-échantillonnage (SMOTE) 7
1.4.2 Apprentissage sensible au coût 7
1.5 Métriques d'évaluation pour données déséquilibrées 7
1.6 Analyse en Composantes Principales (ACP) et anonymisation 7

2 Analyse Exploratoire des Données **8**
2.1 Qualité des données 8
2.2 Statistique Descriptive 9
2.3 Le Déséquilibre des Classes 9
2.4 Analyse des Valeurs Extrêmes 10
2.5 Analyse Bivariée 10

3 Préparation des Données et Split **11**

4 Choix Méthodologiques : Variables et Algorithmes **12**
4.1 L'absence de tests de significativité 12
4.2 Justification des Algorithmes retenus (et écartés) 12

5 Gestion du Déséquilibre et Étude Comparative **14**
5.1 Résultats de la Régression Logistique (Baseline) 15
5.2 Résultats du Random Forest 16
5.3 Résultats de XGBoost 16
5.4 Résultats de LightGBM 17
5.5 Conclusion 17

6 Architecture et Implémentation du Framework **18**

Conclusion Générale **19**

Liste des figures

Figure 2.1 – Analyse des valeurs manquantes
Figure 2.2 – Statistique Descriptive
Figure 2.3 – Distribution des transactions
Figure 2.4 – Visualisation des Valeurs Extrêmes
Figure 2.5 – Analyse Bivariée ; transaction par tranche de montant
Figure 5.1 – Régression Logistique
Figure 5.2 – Random Forest
Figure 5.3 – XGBoost
Figure 5.4 – LightGBM
Figure 6.1 – Framework

Introduction Générale

La fraude à la carte bancaire représente un enjeu financier majeur pour les institutions financières mondiales. L'objectif de ce projet est de concevoir un système de détection de fraude robuste en utilisant des techniques de Machine Learning.

Le principal défi de ce projet réside dans la nature même des données : un déséquilibre de classes extrême. Sur des centaines de milliers de transactions, seule une infime fraction est frauduleuse. Un modèle naïf prédisant que toutes les transactions sont légitimes obtiendrait une précision de 99,8 %, tout en étant parfaitement inutile sur le plan métier.

L'enjeu de cette étude est donc de dépasser la simple "Précision" (Accuracy) pour se concentrer sur l'optimisation de la zone sous la courbe de précision-rappel (AUPRC), tout en trouvant le meilleur compromis métier entre la détection maximale des fraudes (Sensibilité/Recall) et la minimisation de l'impact sur l'expérience client (limitation des Fausses Alertes).

Chapitre 1

Fondements Théoriques

1.1 La fraude bancaire : définition, typologie et enjeux

La fraude bancaire est une opération financière trompeuse visant à obtenir un avantage illicite. Elle se manifeste sous plusieurs formes :

- **Le vol de carte physique :** Utilisation d'une carte perdue ou volée avant opposition.
- **Le skimming :** Copie clandestine de la bande magnétique via des terminaux compromis.
- **Le phishing :** Manipulation de la victime pour qu'elle révèle ses identifiants.
- **Le Card-Not-Present (CNP) :** Exploitation des numéros de carte pour des achats en ligne sans présentation physique.

L'enjeu principal est de trouver un équilibre délicat : maximiser la détection pour limiter les pertes, tout en minimisant les fausses alertes qui génèrent des coûts opérationnels et de l'insatisfaction client.

1.2 Apprentissage automatique pour la classification

Dans le cadre de l'apprentissage supervisé, le modèle apprend une fonction de décision $f(x)$ associant les caractéristiques d'une transaction à une probabilité de fraude. Formellement, pour un espace d'entrée $\mathcal{X}$ et de sortie $\mathcal{Y} = \{0, 1\}$, on cherche une fonction $h : \mathcal{X} \to \mathcal{Y}$ minimisant le risque empirique :

$$R(h) = \frac{1}{n} \sum_{i=1}^{n} L(h(x_i), y_i)$$

où L est la fonction de perte mesurant l'écart entre prédiction et réalité.

Le compromis **biais-variance** est central : le biais reflète une erreur due à des hypothèses trop simples (sous-apprentissage), tandis que la variance reflète une sensibilité excessive aux fluctuations d'entraînement (surapprentissage). Les méthodes ensemblistes visent à réduire ces deux composantes.

1.3 Algorithmes de classification

1.3.1 Régression Logistique

La régression logistique est un modèle statistique de classification qui modélise la probabilité d'appartenance à la classe positive en utilisant la fonction de lien *logit* (le logarithme du rapport de cotes, ou *odds*) :

$$logit(p) = \ln\left(\frac{p}{1-p}\right) = w^\top x + b$$

où $p = P(Y = 1|X = x)$, w représente le vecteur des poids et b le biais.

En appliquant la fonction inverse (la fonction sigmoïde), on retrouve la probabilité directement calculable :

$$P(Y = 1|X = x) = \frac{1}{1 + \exp(-(w^\top x + b))}$$

Bien qu'elle fournisse des probabilités bien calibrées et qu'elle soit hautement interprétable, sa nature linéaire la limite face à des frontières de décision complexes, servant ainsi de modèle de référence (baseline) dans notre étude.

1.3.2 Arbres de décision et Forêts Aléatoires

Un arbre divise l'espace en maximisant un critère de pureté, comme l'indice de Gini :

$$Gini(t) = 1 - \sum_k p_k(t)^2$$

Pour pallier la forte variance d'un arbre unique, les Forêts Aléatoires (Bagging) construisent de multiples arbres sur des échantillons bootstrap et font voter les prédictions. La variance de la forêt est approximativement réduite selon la formule :

$$Var(\overline{f}) \approx \rho\sigma^2 + \frac{(1-\rho)\sigma^2}{B}$$

1.3.3 Gradient Boosting : XGBoost et LightGBM

Le Boosting construit des modèles séquentiellement pour corriger les erreurs résiduelles. La prédiction après m itérations est :

$$F_m(x) = F_{m-1}(x) + \eta h_m(x)$$

- **XGBoost :** Introduit une régularisation pénalisant la complexité et accélère la recherche de division.
- **LightGBM :** Utilise l'échantillonnage GOSS et une croissance des arbres en feuilles (leaf-wise) pour des performances optimales sur de grands volumes de données.

1.4 Le problème du déséquilibre de classes

Avec moins de 0,2 % de fraudes, les modèles standard sont biaisés. Deux approches principales existent :

1.4.1 Sur-échantillonnage (SMOTE)

Génère des exemples synthétiques par interpolation avec les plus proches voisins :

$$x_{new} = x_i + \delta(x_{z_i} - x_i), \quad \delta \sim \mathcal{U}(0,1)$$

1.4.2 Apprentissage sensible au coût

Modifie la fonction de perte en appliquant des poids inversement proportionnels aux fréquences :

$$W_i = \frac{n}{2n_i}$$

1.5 Métriques d'évaluation pour données déséquilibrées

L'Accuracy étant trompeuse, l'évaluation s'appuie sur la Précision et le Rappel :

$$Precision = \frac{VP}{VP + FP}$$

$$Rappel = \frac{VP}{VP + FN}$$

Le F1-Score représente leur moyenne harmonique :

$$F_1 = \frac{2 \times Precision \times Rappel}{Precision + Rappel}$$

Face au déséquilibre, l'**AUPRC** (Aire sous la courbe Précision-Rappel) est privilégiée par rapport à l'AUC-ROC, car elle sanctionne immédiatement l'augmentation des Faux Positifs.

1.6 Analyse en Composantes Principales (ACP) et anonymisation

L'ACP transforme des variables corrélées en composantes indépendantes en décomposant la matrice de covariance. Dans ce projet, l'ACP anonymise les données sensibles et élimine la multicolinéarité. Les variables étant déjà transformées, les tests de significativité univariée sont obsolètes ; les algorithmes évaluent d'eux-mêmes l'importance des variables.

Chapitre 2

Analyse Exploratoire des Données

2.1 Qualité des données

Le jeu de données est exceptionnellement propre. L'analyse des valeurs manquantes confirme qu'aucune imputation n'est nécessaire.

#	Column	Non-Null Count	Dtype
0	Time	284807 non-null	float64
1	V1	284807 non-null	float64
2	V2	284807 non-null	float64
3	V3	284807 non-null	float64
4	V4	284807 non-null	float64
5	V5	284807 non-null	float64
6	V6	284807 non-null	float64
7	V7	284807 non-null	float64
8	V8	284807 non-null	float64
9	V9	284807 non-null	float64
10	V10	284807 non-null	float64
11	V11	284807 non-null	float64
12	V12	284807 non-null	float64
13	V13	284807 non-null	float64
14	V14	284807 non-null	float64
15	V15	284807 non-null	float64
16	V16	284807 non-null	float64
17	V17	284807 non-null	float64
18	V18	284807 non-null	float64
...			
29	Amount	284807 non-null	float64
30	Class	284807 non-null	int64

FIGURE 2.1 – Analyse des valeurs manquantes

2.2 Statistique Descriptive

L'analyse statistique préliminaire révèle des échelles très différentes entre les variables Time et Amount.

	Time	Amount
count	284807.000000	284807.000000
mean	94813.859575	88.349619
std	47488.145955	250.120109
min	0.000000	0.000000
25%	54201.500000	5.600000
50%	84692.000000	22.000000
75%	139320.500000	77.165000
max	172792.000000	25691.160000

FIGURE 2.2 – Statistique Descriptive

2.3 Le Déséquilibre des Classes

La visualisation de la distribution des transactions (échelle logarithmique) met en évidence le défi principal du projet : le déséquilibre massif entre la classe 0 (Légitime) et la classe 1 (Fraude).

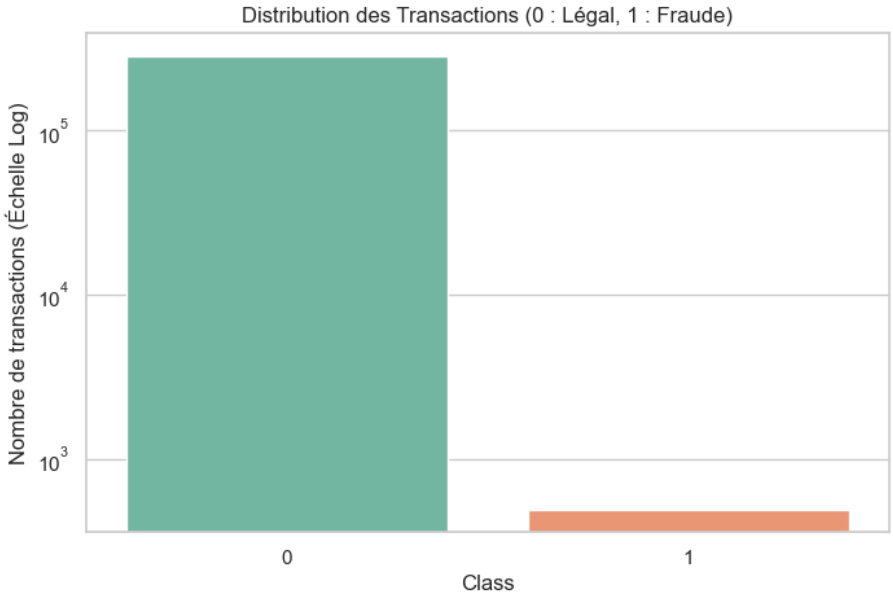


FIGURE 2.3 – Distribution des transactions

2.4 Analyse des Valeurs Extrêmes

L'étude de la variable Amount via un diagramme en boîte (boxplot) révèle une forte asymétrie avec des valeurs extrêmes allant jusqu'à plus de 25 000.

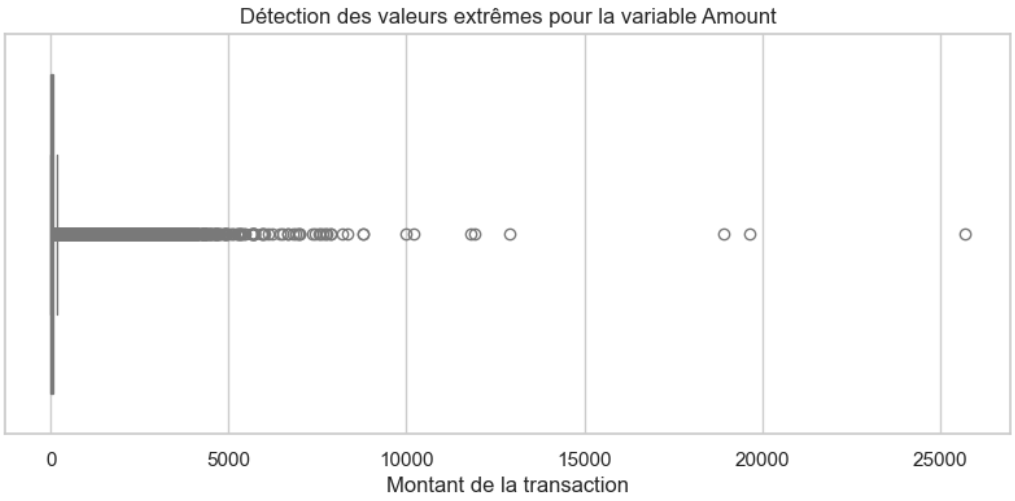


FIGURE 2.4 – Visualisation des Valeurs Extrêmes

Bien qu'il soit courant de supprimer les outliers en statistiques classiques, nous avons pris la décision de les conserver. Dans un contexte de fraude, une transaction au montant anormalement élevé porte une information cruciale qui ne doit pas être détruite.

2.5 Analyse Bivariée

L'analyse par tranches de montants permet de comprendre la répartition des fraudes en fonction du volume financier de la transaction.

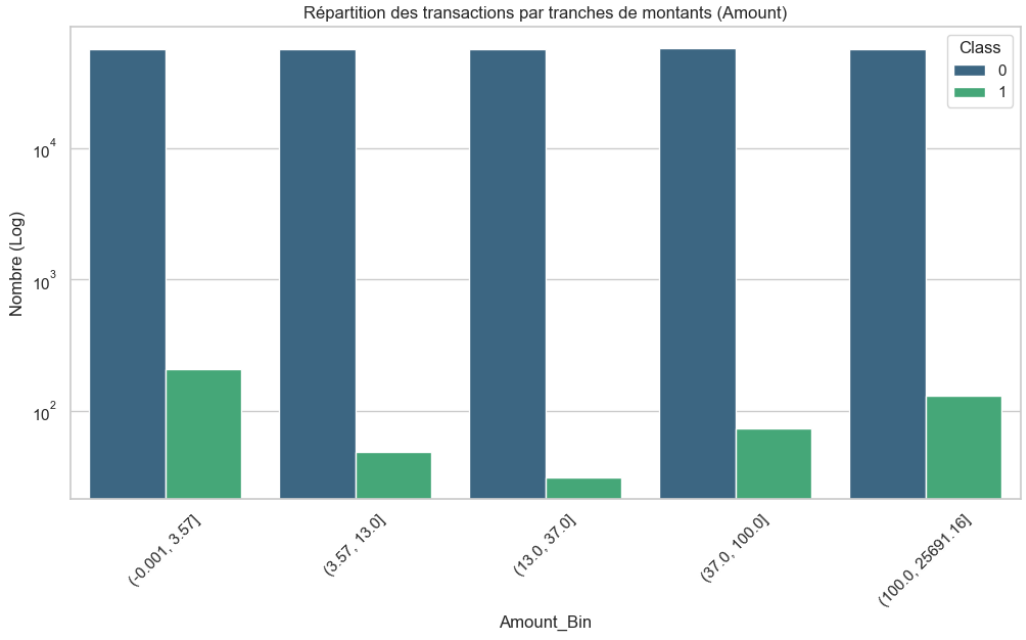


FIGURE 2.5 – Analyse Bivariée ; transaction par tranche de montant

Chapitre 3

Préparation des Données et Split

Pour garantir une évaluation fiable et éviter toute fuite d'information (Data Leakage), la préparation des données a suivi un protocole strict :

Séparation Stratifiée (Train/Test Split) : Le jeu de données a été divisé en conservant exactement la même proportion de fraudes dans les ensembles d'entraînement et de test (stratify=y). C'est une étape vitale face à un déséquilibre aussi fort.

Mise à l'échelle (Scaling) : Contrairement au StandardScaler classique qui est très sensible aux valeurs extrêmes, nous avons opté pour le RobustScaler. Ce dernier utilise la médiane et l'intervalle interquartile (IQR), ce qui permet de normaliser les variables Time et Amount sans être faussé par les transactions aux montants gigantesques observées lors de l'EDA.

Chapitre 4

Choix Méthodologiques : Variables et Algorithmes

4.1 L'absence de tests de significativité

Dans ce projet, nous n'avons pas réalisé de tests statistiques classiques (Student, Chi-2) pour écarter des variables avant la modélisation. Ce choix s'appuie sur deux raisons :

La nature des données (PCA) : Les variables V1 à V28 sont issues d'une Analyse en Composantes Principales (ACP) préalablement appliquée par la banque pour anonymiser les données. Ces composantes sont déjà orthogonales (indépendantes) et concentrent la variance. Tester leur significativité univariée détruirait l'information latente.

L'approche Machine Learning : Contrairement à l'économétrie classique qui cherche l'inférence causale, notre but est la prédiction. Nous laissons aux algorithmes ensemblistes le soin de calculer eux-mêmes l'Importance des Variables (Feature Importance) lors de la construction des arbres.

4.2 Justification des Algorithmes retenus (et écartés)

Notre stratégie a consisté à procéder par paliers de complexité :

Régression Logistique : Utilisée comme Baseline (modèle de référence). Elle est rapide, interprétable, et fixe le score minimum à battre.

Random Forest (Bagging) : Utilisé pour gérer la non-linéarité et éviter le surapprentissage extrême dont souffrirait un simple Arbre de Décision unique sur ce type de données.

XGBoost & LightGBM (Boosting) : L'état de l'art pour les données tabulaires, permettant d'optimiser séquentiellement les erreurs et offrant une rapidité d'exécution supérieure (notamment LightGBM).

Pourquoi avoir écarté SVM, KNN, LDA, QDA et Naive Bayes (Multinomial et Gaussien) ?

SVM et KNN : Incapables de passer à l'échelle (scalabilité) sur un dataset de plus de 280 000 lignes. Le temps de calcul euclidien du KNN ou l'entraînement du SVM satureraient la mémoire et seraient inexploitables pour une prédiction bancaire en temps réel.

LDA / QDA : Ces méthodes supposent une distribution normale des données. Notre

EDA a prouvé la présence de valeurs extrêmes massives qui détruiraient les matrices de covariance de ces modèles.

Naive Bayes (Multinomial et Gaussien) : Bien que l'algorithme Naive Bayes soit un grand classique du Machine Learning, reconnu pour sa rapidité et sa légèreté, il présente des limitations théoriques et mathématiques majeures qui le rendent incompatible avec notre projet.

Premièrement, la version Multinomial Naive Bayes exige des données strictement positives (souvent des fréquences ou des comptages). Or, nos variables V1 à V28 issues de l'ACP sont continues et contiennent de très nombreuses valeurs négatives (correspondant souvent aux signatures mêmes de la fraude). Son utilisation est donc mathématiquement impossible sur ce jeu de données. Deuxièmement, bien que la version continue (Gaussian Naive Bayes) accepte les valeurs négatives, elle repose sur l'hypothèse "naïve" d'indépendance totale entre les variables. Or, une fraude financière complexe se caractérise par des interactions croisées subtiles entre plusieurs composantes simultanément. Contrairement aux méthodes ensemblistes (Random Forest, Boosting) qui excellent dans la modélisation de ces relations non linéaires, Naive Bayes est structurellement incapable de capturer ces interactions, le rendant trop simpliste pour ce niveau de complexité.

Chapitre 5

Gestion du Déséquilibre et Étude Comparative

Pour chaque algorithme, 4 environnements de données ont été testés :

Baseline Cost-Sensitive : Pénalise mathématiquement les erreurs sur la classe minoritaire sans modifier les données (class-weight='balanced').

Under-sampling : Suppression de transactions normales pour égaler le nombre de fraudes.

SMOTE (Sur-échantillonnage) : Création de fraudes synthétiques par interpolation avec les plus proches voisins.

SMOTETomek (Hybride) : Génération SMOTE suivie d'un nettoyage des frontières ambiguës via les liens de Tomek.

5.1 Résultats de la Régression Logistique (Baseline)

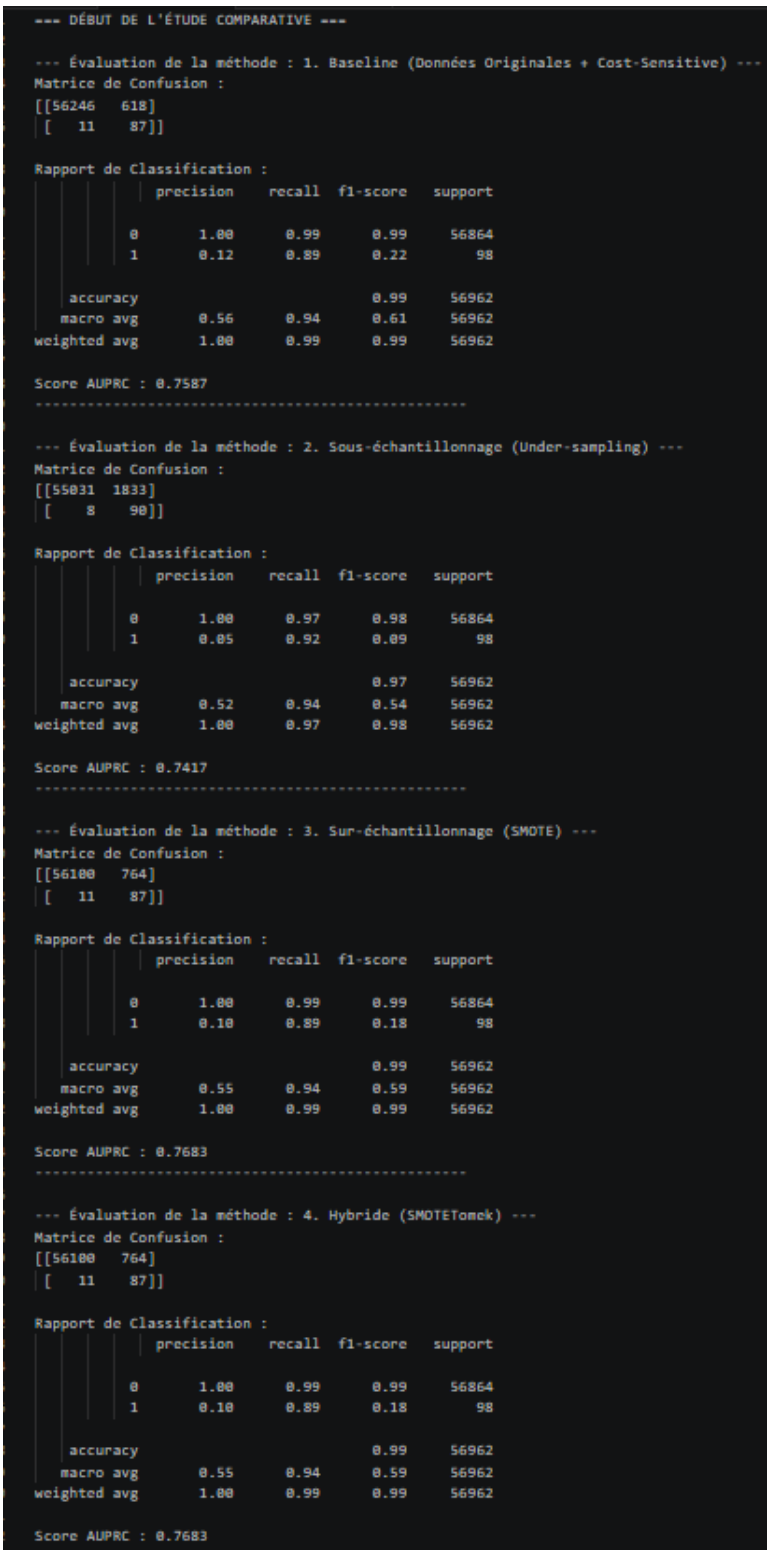


FIGURE 5.1 – Régression Logistique

L'Under-sampling détruit trop d'informations, causant une explosion des fausses alertes (1833). La baseline Cost-sensitive offre le meilleur compromis linéaire (AUPRC : 0.7587).

5.2 Résultats du Random Forest

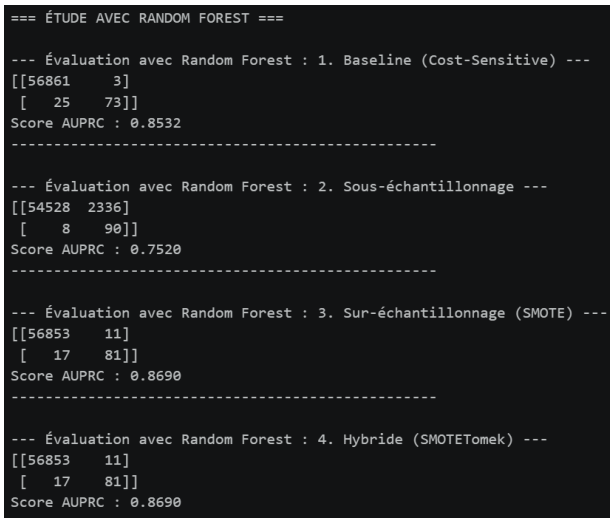


FIGURE 5.2 – Random Forest

Le passage à un modèle non-linéaire est spectaculaire. Couplé à SMOTE, le Random Forest fait chuter les fausses alertes de 764 (LogReg) à seulement 11, obtenant un excellent score AUPRC de 0.8690.

5.3 Résultats de XGBoost

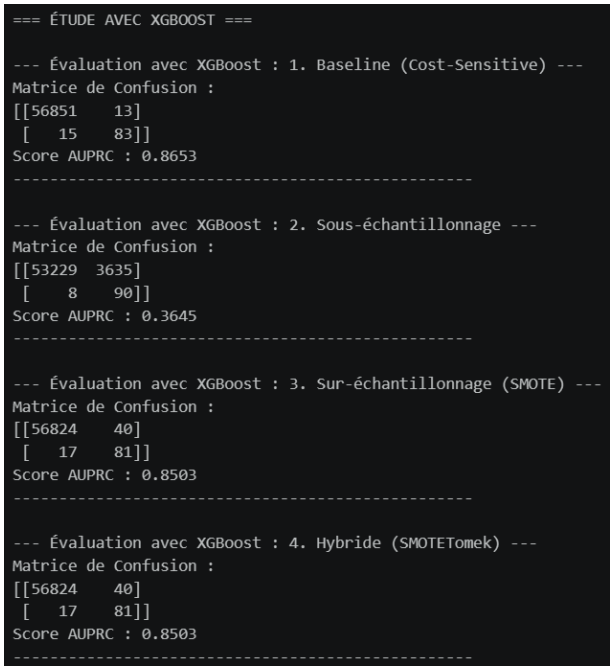


FIGURE 5.3 – XGBoost

XGBoost prouve la supériorité de la méthode Cost-Sensitive (AUPRC : 0.8653), détectant 83 fraudes avec un minimum de fausses alertes (13). Il démontre également que le Sous-échantillonnage est définitivement inopérant (AUPRC effondré à 0.3645).

5.4 Résultats de LightGBM

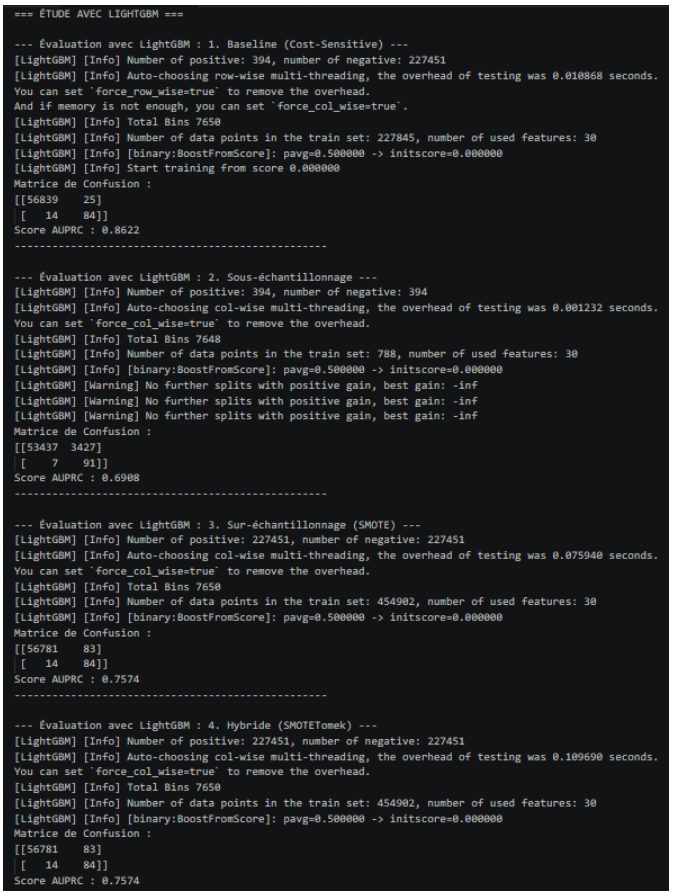


FIGURE 5.4 – LightGBM

LightGBM en mode Cost-Sensitive excelle en détectant le maximum de fraudes absolues (84), tout en conservant un temps d'exécution extrêmement rapide et une AUPRC de 0.8622.

5.5 Conclusion

À l'issue de cette batterie de tests exhaustifs croisant 4 algorithmes avec 4 stratégies de rééchantillonnage, un grand gagnant se détache pour répondre aux exigences strictes du secteur bancaire : le Random Forest couplé au sur-échantillonnage SMOTE.

Bien que les algorithmes de Gradient Boosting (XGBoost et LightGBM) en mode Cost-Sensitive aient montré de remarquables capacités de détection (jusqu'à 84 fraudes attrapées), la combinaison Random Forest + SMOTE offre le compromis métier le plus sécurisant. Avec le meilleur score AUPRC global (0.8690), ce modèle réussit à détecter 81 fraudes tout en écrasant le nombre de fausses alertes à seulement 11 (contre 25 pour LightGBM, 13 pour XGBoost, et plus de 760 pour la Régression Logistique).

En minimisant aussi drastiquement les Faux Positifs, ce modèle garantit la sécurité financière de la banque sans détériorer l'expérience des clients légitimes. C'est donc cette combinaison précise (SMOTE + Random Forest) qui est officiellement retenue pour la suite du projet, et qui fera l'objet d'une industrialisation dans notre framework final.

Chapitre 6

Architecture et Implémentation du Framework

Afin de garantir la robustesse de notre solution pour une potentielle mise en production, nous n'avons pas traité les étapes de manière isolée. Nous avons développé un véritable Framework en encapsulant notre processus dans une Pipeline logicielle de la bibliothèque imbalanced-learn.

L'utilité de cette architecture est double :

Automatisation : La pipeline enchaîne la standardisation (RobustScaler), la méthode de rééchantillonnage (SMOTE) et la modélisation (Random Forest).
Prévention de la fuite de données : Elle garantit que la génération de données synthétiques (SMOTE) ne s'applique strictement qu'aux données d'entraînement (X-train), laissant les données de test totalement intactes et représentatives de la réalité.

Voici la représentation architecturale de la Pipeline finale déployée et exportée via joblib :

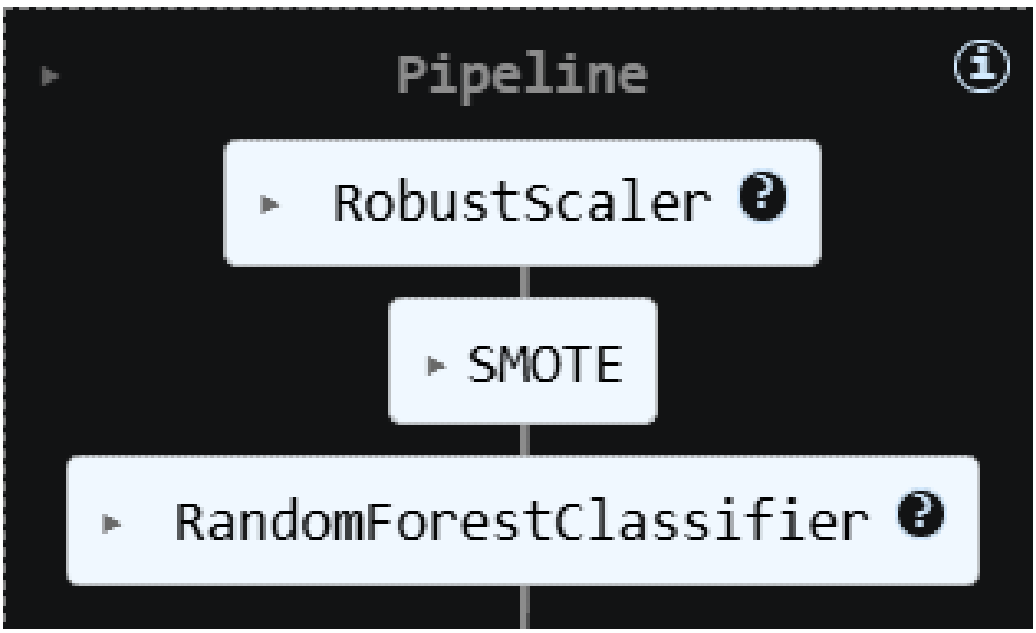


Figure 6.1 – Framework

Conclusion Générale

Cette étude a permis de traverser le cycle de vie complet d'un projet de Data Science complexe, de l'exploration de données asymétriques à l'encapsulation logicielle via une Pipeline.

Sur le plan technique, nous avons démontré que :

L'Under-sampling est à proscrire sur ce type de données, car la perte d'information sur la classe majoritaire détruit la précision du modèle.

Les algorithmes d'arbres ensemblistes surpassent largement les approches linéaires face aux valeurs aberrantes et aux relations non linéaires.

Le choix du modèle final dépendra de la politique commerciale de l'institution financière :

Si l'objectif est de minimiser la friction client (moins de cartes bloquées par erreur), le modèle Random Forest couplé à SMOTE est le grand vainqueur (seulement 11 fausses alertes pour un AUPRC de 0.8690).

Si l'objectif est la simplicité de l'architecture de données en production, nous recommandons XGBoost ou LightGBM en mode Cost-Sensitive. Ces modèles offrent une détection de fraude légèrement supérieure (83 à 84 fraudes détectées) sans nécessiter la génération de données synthétiques en amont, ce qui allège considérablement les opérations sur les serveurs en temps réel.